

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 2. Les principes généraux de la statistique
Les paramètres statistiques élémentaires
Exercices GéoSUDS – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler un fichier C.S.V.
- Faire des sorties graphiques
- Utiliser les bibliothèques `Pandas` (données) et `Matplotlib` (graphiques)
N.B. `pd` et `plt` sont des alias qui remplacent respectivement `pandas` et `matplotlib.pyplot`.
- Calculer des effectifs
- Calculer des fréquences
- Faire des graphiques (diagrammes en bâton et circulaires, et histogrammes)
- Découvrir les méthodes de `Pandas` permettant de calculer les paramètres d'une série statistique
- Tracer une boîte de dispersion

2 Manipulations

1. Dans le dossier `src`, créer un dossier `data` et y introduire le fichier `Afrique-2024.csv` disponible dans la Seance-02 du GitHub
N.B. `country_names.xls` et `hs92-6-digit.xls` contient respectivement les métadonnées des codes ISO des territoires et des produits des produits échangés.
2. Dans le dossier `src`, introduire le fichier `main.py` de la séance disponible dans la Seance-02 du GitHub
3. Ouvrir le fichier `main.py` dans votre éditeur de code (Notepad++ ou VS Code)
4. Repérer l'instruction `with`. Elle permet par l'intermédiaire d'une variable appelée `fichier` de lire le fichier C.S.V. grâce à la méthode `read_csv(...)` de la bibliothèque `Pandas`.
N.B. Bien que `Pandas` puisse lire les fichiers Excel, il faut vous habituer à utiliser des formats textuels comme le format C.S.V.
5. Afficher sur le terminal exécutant le conteneur la variable `contenu` avec la méthode de `Pandas DataFrame(...)`
6. Calculer avec la fonction native `len(...)` le nombre de lignes et de colonnes du tableau de données et les afficher sur le terminal
7. Afficher sur le terminal le nom des colonnes, c'est-à-dire la première ligne avec la méthode `Pandas head()`
8. Faire le point sur la nature statistique des variables en utilisant le lien vers les métadonnées fourni en commentaire. Faire une liste sur le type de chaque colonne (`int`, `float`, `str` ou `bool`).
9. À l'aide du nom des colonnes affiché, sélectionner les exportations et les importations en tonnes
10. Calculer les effectifs totaux des exportations et des importations pour chaque territoire. Afficher le résultat sur le terminal. Normalement, vous devez obtenir deux valeurs identiques.
Attention! Pour effectuer le calcul, il faut supprimer les valeurs "-" des deux colonnes. Il faut par conséquent imbriquer une boucle et une condition afin de ne compter que les nombres.
11. À l'aide de `Matplotlib` et de la boucle imbriquée que vous devez compléter, faire des diagrammes en barres avec le volume total des exportations et des importations en dollars courants (USD) pour chaque territoire référence. Créer les fichiers images des diagrammes.
 - a. Créer un sous-dossier `img` dans le dossier `src`.
 - b. Sélectionner les colonnes `origin_id`, `export_val` et `import_val`. Les mettre en paramètres de la fonction `listedesterritoires( code du territoire, exportations, importations )` (bien respect l'ordre indiqué sinon la fonction calculera n'importe quoi). Cette fonction calcule la valeur totale des exportations et des importations en dollars courants (USD).

c. Construire la liste des territoires

Indice. Utiliser la méthode native `append(...)`

d. Sélectionner chaque territoire de référence avec une boucle et compter la somme des exportations et des importations.

Indice. Utiliser la méthode `Pandas sum(...)`

e. Construire les diagrammes circulaires avec les données extraites pour chaque territoire de référence, utiliser le code ISO pour titrer vos graphiques, et les sauvegarder dans le dossier `img`

N.B. 1. Vous allez créer de nombreux fichiers. Créer un nouveau sous-dossier pour stocker vos images.

N.B. 2. Privilégier le format `*.png`, qui est un format léger non propriétaire

12. Sélectionner les colonnes contenant des caractères quantitatifs (`distance`, `export USD`, `import USD`, `export ton` et `import ton`)? Ces cinq colonnes contiennent des chaînes de caractères. Avant de lancer n'importe quel calcul, il faut nettoyer chaque colonne avec la fonction `nettoyage(...)` qui prend en paramètre la colonne à nettoyer. Pour vous aider, utiliser une liste permettant de découper les données en fonction du territoire. Vous pouvez utiliser `liste = getliste(...)` qui prend en paramètre la colonne `origin_id`. Créer un nouvel objet `Pandas` :

```
donnees2titre = ["distance", "export_val_2", "import_val_2",  
                 "export_ton_2", "import_ton_2"]
```

```
donnees2 = pd.DataFrame({donnees2titre[0] : liste des distances  
                        nettoyées, donnees2titre[1] : liste des exportations (USD) nettoyées,  
                        donnees2titre[2] : liste des importations (USD) nettoyées, donnees2titre[3] :  
                        des exportations (tonnes) nettoyées, donnees2titre[4] : liste des impor-  
                        tations (tonnes) nettoyées})
```

Il faut remplacer les expressions en italique par le nom de vos listes. À l'aide de la boucle imbriquée à compléter, calculer sous la forme d'une liste :

- les moyennes de chaque colonne avec la bonne méthode de `Pandas` ;
- les médianes de chaque colonne avec la bonne méthode de `Pandas` ;
- les modes de chaque colonne avec la bonne méthode de `Pandas` ;
- l'écart type de chaque colonne avec la bonne méthode de `Pandas` ;
- l'écart absolu à la moyenne de chaque colonne avec la bonne méthode de `Pandas` ;
- l'étendue de chaque colonne.

N.B. 1. Utiliser la méthode de la valeur absolue `abs()` disponible dans `Numpy`

N.B. 2. Utiliser les méthodes `min()` et `max()` disponibles dans `Pandas`

En utilisant la méthode `round()` de `Pandas`, arrondir tous les paramètres à deux décimaux.

13. Afficher la liste des paramètres sur le terminal

14. Calculer les distances interquartile et interdécile de chaque colonne quantitative avec la méthode `quantile()` dans `Pandas` ?

N.B. Vous pouvez utiliser la boucle précédente pour calculer les deux distances inter-quantiles.

15. À l'aide de `Matplotlib` et d'une boucle, faire des boîtes à moustache de chaque colonne quantitative. Stocker les résultats dans un dossier `img`.

Attention! Vous devez nommer les fichiers avec d'autres noms que ceux des diagrammes circulaires créés précédemment.

16. Sélectionner la colonne `Dist_VO` (km) et écrire un algorithme pour catégoriser et dénombrer le nombre de distances ayant une distance comprise :

- entre 0 et 2 500 km ou `]0, 2500]` ;
- entre 2 500 et 5 000 km ou `]2500, 5000]` ;
- entre 5 000 et 7 500 km ou `]5000, 7500]` ;
- entre 7 500 et 10 000 km ou `]7500, 10000]` ;
- entre 10 000 et 12 500 km ou `]10000, 12500]` ;
- entre 12 500 et 15 000 km ou `]12500, 15000]` ;
- entre 15 000 et 17 500 km ou `]15000, 17500]` ;
- entre 17 500 et 20 000 km ou `]17500, 20000]`.

Vous concevrez un organigramme pour expliquer votre solution. L'objectif de cette dernière question est d'apprendre à catégoriser des variables quantitatives.

Je rappelle la différence entre un diagramme en bâtons et un histogramme. Le premier sert à représenter des données, le second, à représenter une distribution statistique. Cela signifie sur la totalité des surfaces des rectangles vaut 1 (cf. cours sur les distributions).

3 Bonus

Sans remarque pour vous aider (conditions réelles), refaire les diagrammes circulaires dans un dossier `img2` en vous aidant du fichier `country_names.xls` remplacer les codes ISO dans le titre des graphiques par le véritable nom du territoire.

Dans des dossiers `csv` et `xlsx`, sortir les listes calculées avec la bonne méthode `Pandas` au format C.S.V. et `Excel`. N'oubliez pas de titrer les colonnes et les lignes de vos sorties si nécessaire.