

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 6. Régression et corrélation statistique de deux variables

Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

21 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à gérer les données censurées
- Manipulation des outils de la régression et de la corrélation simple

2 Manipulations

Existe-t-il un lien entre la valeur des importations et des exportations en dollars courants par territoire au niveau des produits alimentaires ?

1. Ouvrir le fichier `Produits-alimentaires-vs-autres.csv`. Isoler chaque colonne `Année`, `Code-ISO`, `Total-export-alimentaire-USD`, `Total-import-alimentaire-USD`, `Total-export-autres-USD`, `Total-import-autres-USD`, `Total-export-USD` et `Total-import-USD`. Ainsi, le fichier regroupe deux agrégats de flux par territoire : (a) les flux concernant les produits alimentaires en dollars courants (`Total-export-alimentaire-USD`

et `Total-import-alimentaire-USD`); (b) les flux concernant les produits non alimentaires (`Total-export-autres-USD` et `Total-import-autres-USD`). Il contient la somme des deux (`Total-export-USD` et `Total-import-USD`).

2. On considère qu'il existe un lien entre importations et exportations. Il est à noter que chaque colonne peut jouer le rôle de la variable explicative de l'autre. Calculer une régression linéaire simple entre chaque paire de colonnes avec la méthode `scipy.stats.linregress(x, y)` prenant en arguments `x`, les importations comme variable à expliquer, et `y`, les exportations comme variable explicative. Que se passe-t-il au niveau des résultats si vous inversez les `x` et `y` ?
3. Calculer la corrélation simple entre chaque paire de colonnes. Vous pouvez utiliser indifféremment les bibliothèques `Pandas` ou `Scipy`.
4. Faire trois graphiques de synthèse permettant de visualiser les trois droites de régression obtenues.
5. Dans votre rapport, vous commenterez votre résultat sous la forme d'un ou deux paragraphes.

3 Bonus

Vous avez écrit un algorithme permettant de traiter deux colonnes se rapportant à la même année. Écrivez un algorithme permettant de généraliser votre résultat à toutes les années de 1995 à 2024 grâce aux fichiers fournis. N'oubliez pas d'organiser correctement vos fichiers de sortie.