

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 7. Étude de deux variables qualitatives

Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

15 septembre 2026

1 Objectifs

- Manipuler des variables qualitatives avec Python
- Calculer les principaux indicateurs de liaison avec la bibliothèque `scipy.stats`

2 Manipulations

Vous allez utiliser les données 2006-2020 de l'Union nationale des industries de carrières et matériaux de construction (U.N.I.C.E.M.) et de l'Union nationale des producteurs de granulats (U.N.P.G.) concernant la relation entre le lieu de production et les années de production <https://www.unicem.fr/services-aux-entreprises/documentation/statistiques>. Si vous avez compris le cours, vous avez compris qu'il s'agit d'un tableau de contingence avec deux variables qualitatives. Normalement, vous le calculerez un tableau croisé dynamique avec la méthode de la bibliothèque Pandas, `crosstab()`. Toutefois, il arrive souvent, comme dans le cas présent, que le tableau de contingence n'ait pas à être calculé. De fait, on ne peut pas utiliser les méthodes de Pandas directement, notamment pour calculer les marges.

Au cas où vous ne connaissez pas ce que sont les granulats, vous pouvez lire le flyer de l'U.N.I.C.E.M. fournit dans les données `UNPG-2017-Tout-savoir-sur-les-granulats.pdf`.

Après avoir chargé les données contenues dans le fichier `France-Granulats-2006-2020-par-region.csv`, appliquer la fonction locale

`tableauDeContingence(..., ...)` qui prend deux paramètres : la colonne de référence, ici, celle des régions, et un dictionnaire contenant le nom des autres colonnes et leurs données.

L'unité du tableau est en millions de tonnes.

1. Calculer les marges des lignes et des colonnes en vous servant des fonctions locales `sommeDesColonnes()` et `sommeDesLignes()`.
2. Faire une condition vérifiant si le total des marges des lignes et le total des marges des colonnes est identique.
3. Faire un test d'indépendance du χ^2 à partir de la bibliothèque `scipy.stats` et de sa méthode `chi2_contingency()`. Existe-t-il une liaison ?
4. Calculer l'intensité de liaison ϕ^2 de Pearson à partir des résultats précédents.
5. Dans votre rapport, faire un court paragraphe expliquant vos résultats.

3 Bonus

Les points bonus sont attribués par rapport aux chapitres d'approfondissement.

Avec le fichier `Echantillonnage-100-Echantillons.csv`, faire une analyse ANOVA.

Avec le tableau de données, calculer une A.F.C. et faisant le commentaire.