

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 9. Les méthodes statistiques multivariées
explicatives
Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

Courage, c'est presque fini !

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à faire une régression linéaire multiple avec Pandas.
- Apprendre à faire une régression linéaire multiple avec Sklearn.

2 Manipulations

L'exercice est relativement simple. À la différence des méthodes factorielles, ici, il s'agit juste de déterminer des coefficients. De fait, deux séries de données vous seront proposées.

1. Ouvrir le fichier `temperature.csv`. Le fichier contient 33 villes des États-Unis (champ `Ville`). Les individus sont caractérisés par une variable à expliquer `Température_en_janvier` et trois variables explicatives `Latitude` (en degré décimal), `Longitude` (en degré décimal) et `altitude` (en mètre).

- Calculer la corrélation entre les quatre variables avec la méthode `corr()` de Pandas.
 - Afficher les statistiques descriptives avec `describe()` de Pandas.
 - Isoler le champ `Ville` et isoler les données en distinguant `Température_en_janvier`, la variable à expliquer, et `Latitude`, `Longitude` et `altitude`, les variables à expliquer.
 - Avec la bibliothèque `statsmodels.api`, calculer la régression linéaire liant la variable à expliquer avec les variables explicatives.
 - En utilisant les attributs et les méthodes de `statsmodels.api`, calculer les paramètres de la régression linéaires (les coefficients), le coefficient de détermination, le résumé de la régression et les *p-values*.
 - Avec `Scikit-Learn`, isoler les coefficients avec l'attribut `coef_`. Isoler la constante de l'ajustement avec la méthode `intercept_`.
 - Dans votre rapport, commenter et analyser les résultats obtenus.
2. Ouvrir le fichier `geomarketing.csv`. Il s'agit d'un exercice que vous pourriez avoir dans une organisation qui vous emploierait. Il faut expliquer la variable `ca`, le chiffre d'affaires de chaque individu représentant le magasin fictif Big Bazar.
- Une A.C.P. a été, au préalable, réalisée sur l'ensemble des variables. Elle a révélé que les variables significatives étaient :
 - `ca`;
 - `surface_totale`;
 - `potentiel_Z20`;
 - `nb_primaire_Z10`;
 - `nb_primaire_Z20`;
 - `nb_gsa_Z10`;
 - `nb_pharmacie_Z5`;
 - `nb_conc2_Z10`;
 - `nb_conc2_Z20`;
 - `P10_POP_Z15`;
 - `P10_MEN_Z10`.
 - Isoler `ca` et isoler les neuf variables significatives.
 - En utilisant les attributs et les méthodes de `statsmodels.api`, calculer les paramètres de la régression linéaires (les coefficients), le coefficient de détermination, le résumé de la régression et les *p-values*.
 - Dans votre rapport, commenter et analyser les résultats obtenus.

3 Bonus

À partir du fichier `geomarketing.csv`, opérer la régression avec la totalité des variables, comparer avec les variables sélectionnées par une A.C.P., et, dans votre rapport, commenter et analyser les résultats obtenus.