

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 2. Les principes généraux de la statistique
Les paramètres statistiques élémentaires
Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler un fichier C.S.V.
- Faire des sorties graphiques
- Utiliser les bibliothèques `Pandas` (données) et `Matplotlib` (graphiques)
N.B. `pd` et `plt` sont des alias qui remplacent respectivement `pandas` et `matplotlib.pyplot`.
- Calculer des effectifs
- Calculer des fréquences
- Faire des graphiques (diagrammes en bâton et circulaires, et histogrammes)
- Découvrir les méthodes de `Pandas` permettant de calculer les paramètres d'une série statistique
- Tracer une boîte de dispersion

2 Manipulations

1. Dans le dossier `src`, créer un dossier `data` et y introduire le fichier `happycntry.csv` disponible dans la Seance-02 du GitHub
2. Dans le dossier `src`, introduire le fichier `main.py` de la séance disponible dans la Seance-02 du GitHub
3. Ouvrir le fichier `main.py` dans votre éditeur de code (Notepad++ ou VS Code)
4. Repérer l’instruction `with`. Elle permet par l’intermédiaire d’une variable appelée `fichier` de lire le fichier C.S.V. grâce à la méthode `read_csv(...)` de la bibliothèque Pandas.
N.B. Bien que Pandas puisse lire les fichiers Excel, il faut vous habituer à utiliser des formats textuels comme le format C.S.V.
5. Afficher sur le terminal exécutant le conteneur la variable `contenu` avec la méthode de Pandas `DataFrame(...)`
6. Calculer avec la fonction native `len(...)` le nombre de lignes et de colonnes du tableau de données et les afficher sur le terminal
7. Afficher sur le terminal le nom des colonnes, c’est-à-dire la première ligne avec la méthode Pandas `head()`
8. Faire le point sur la nature statistique des variables en utilisant le lien vers les métadonnées fourni en commentaire. Faire une liste sur le type de chaque colonne (`int`, `float`, `str` ou `bool`).
9. À l’aide du nom des colonnes affiché, sélectionner `Extremely unhappy`, 1, 2, 3, 4, 5, 6, 7, 8, 9 et `Extremely happy`
10. En utilisant les méthodes Pandas `sum(...)` et `iloc[...]`, calculer les effectifs de chaque ligne et les placer dans une liste (à l’aide d’une boucle). Afficher le résultat sur le terminal.

Indice. Utiliser la méthode native `append(...)`

11. À l’aide de Matplotlib et d’une boucle, créer les graphiques suivants.
 - a. Créer un sous-dossier `img` dans le dossier `src`.
 - b. Faire un diagramme circulaire pour chaque territoire. Sauvegarder les images créées dans le dossier `img`.
 - c. Appliquer la méthode Pandas `transpose()` au tableau de données initial. Vous venez d’échanger les lignes avec les colonnes, et les colonnes avec les lignes. Si vous ne comprenez pas, visualiser le nouveau tableau. Vous venez de créer, ce que l’on appelle en calcul matriciel, la transposée du tableau initial. À partir du tableau transposé, réaliser un diagramme en bâtons pour chaque échelle de bonheur. Sauvegarder les images créées dans le dossier `img`.

Attention ! Le diagramme en bâtons va nécessiter de transformer un peu vos données. Reportez-vous au lien suivant :

<https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.plot.bar.html#pandas.DataFrame.plot.bar>.

N.B. 1. Vous allez créer de nombreux fichiers. Créer un nouveau sous-dossier pour stocker vos images.

N.B. 2. Privilégier le format `*.png`, qui est un format léger non propriétaire

12. Dans le tableau initial **et** dans le tableau transposé, à l'aide de la boucle, calculer sous la forme d'une liste :

- les moyennes de chaque colonne avec la bonne méthode de `Pandas` ;
- les médianes de chaque colonne avec la bonne méthode de `Pandas` ;
- les modes de chaque colonne avec la bonne méthode de `Pandas` ;
- l'écart type de chaque colonne avec la bonne méthode de `Pandas` ;
- l'écart absolu à la moyenne de chaque colonne avec la bonne méthode de `Pandas` ;
- l'étendue de chaque colonne.

N.B. 1. Ne pas faire de calculs avec les colonnes (ou lignes) `"code_ISO"` et `"country"`. Il faut réaliser une condition excluant l'application des calculs demandés.

N.B. 1. Utiliser la méthode de la valeur absolue `abs()` disponible dans `Numpy`

N.B. 2. Utiliser les méthodes `min()` et `max()` disponibles dans `Pandas`

En utilisant la méthode `round()` de `Pandas`, arrondir tous les paramètres à deux décimaux.

13. Afficher la liste des paramètres sur le terminal

14. En utilisant le tableau initial **et** en utilisant le tableau transposé, calculer les distances interquartile et interdécile de chaque colonne quantitative avec la méthode `quantile()` dans `Pandas` ?

N.B. 1 Vous pouvez utiliser la boucle précédente pour calculer les deux distances interquartiles.

N.B. 2 `round()` pourra vous déclencher une erreur. Pour la résoudre, il faudra utiliser la fonction native `round()`, au lieu de la méthode `Pandas round()`. C'est subtil. N'hésitez à poser des questions.

15. En utilisant le tableau transposé, à l'aide de `Matplotlib` et d'une boucle, faire des boîtes à moustache de chaque colonne quantitative. Stocker les résultats dans un dossier `img`.

Attention! Vous devez nommer les fichiers avec d'autres noms que ceux des diagrammes circulaires et en bâtons créés précédemment.

16. En utilisant le tableau initial, pour chaque colonne, écrire un algorithme pour catégoriser et dénombrer le nombre de taux ayant une valeur comprise :

- entre 0 et 5 % ou `]0, 5]` ;
- entre 5 et 10 % ou `]5, 10]` ;
- entre 10 et 15 % ou `]10, 15]` ;

- entre 15 et 20 % ou $]15, 20]$;
- entre 20 et 25 % ou $]20, 25]$;
- entre 25 et 30 % ou $]25, 30]$;
- entre 30 et 35 % ou $]30, 35]$;
- entre 35 et 40 % ou $]35, 40]$;
- entre 40 et 45 % ou $]40, 45]$.

Vous concevrez un organigramme pour expliquer votre solution. L'objectif de cette dernière question est d'apprendre à catégoriser des variables quantitatives.

Je rappelle la différence entre un diagramme en bâtons et un histogramme. Le premier sert à représenter des données, le second, à représenter une distribution statistique. Cela signifie sur la totalité des surfaces des rectangles vaut 1 (cf. cours sur les distributions).

3 Bonus

Dans des dossiers `csv` et `xlsx`, sortir les listes calculées avec la bonne méthode `Pandas` au format `C.S.V.` et `Excel`. N'oubliez pas de titrer les colonnes et les lignes de vos sorties si nécessaire.