

Séance 4 Statistiques inférentielles

1. Comment définir l'échantillonnage ? Pourquoi ne pas utiliser la population en entier ? Quelles sont les méthodes d'échantillonnage ? Comment les choisir ?

L'échantillonnage consiste à sélectionner une partie d'une population, appelée échantillon, afin d'obtenir des informations sur l'ensemble de cette population. On n'utilise pas toujours la population entière car cela peut être trop long, trop coûteux ou impossible lorsque la population est très importante.

Il existe plusieurs méthodes : l'échantillonnage aléatoire simple, où chaque individu a la même probabilité d'être sélectionné ; l'échantillonnage systématique, où les individus sont sélectionnés à intervalles réguliers ; l'échantillonnage stratifié, où la population est divisée en groupes ; et l'échantillonnage par grappes, où l'on sélectionne des groupes entiers. Le choix dépend de la structure de la population, des données disponibles et de l'objectif de l'étude. L'objectif est d'obtenir un échantillon le plus représentatif possible.

2. Comment définir un estimateur et une estimation ?

Un estimateur est une statistique calculée à partir d'un échantillon afin d'approcher un paramètre inconnu de la population. L'estimation est la valeur obtenue grâce à cet estimateur. Par exemple, la moyenne calculée sur un échantillon peut servir d'estimateur de la moyenne de la population.

3. Comment distingueriez-vous l'intervalle de fluctuation et l'intervalle de confiance ?

L'intervalle de fluctuation part d'un paramètre connu de la population et indique dans quelle plage les résultats des échantillons peuvent varier sous l'effet du hasard. L'intervalle de confiance suit le raisonnement inverse : il part d'un échantillon pour estimer un paramètre inconnu de la population. Ainsi, l'intervalle de fluctuation va de la population vers l'échantillon, tandis que l'intervalle de confiance va de l'échantillon vers la population.

4. Qu'est-ce qu'un biais dans la théorie de l'estimation ?

Un biais est une erreur systématique qui conduit à surestimer ou sous-estimer le paramètre recherché. Il peut provenir de la constitution de l'échantillon, de la collecte des données ou de la méthode d'estimation utilisée. Par exemple, un échantillon qui représente mal certaines catégories de la population peut produire une estimation biaisée.

5. Comment appelle-t-on une statistique travaillant sur la population totale ? Faites le lien avec la notion de données massives.

Une statistique travaillant sur l'ensemble de la population est une statistique exhaustive. Les données massives permettent aujourd'hui de traiter des volumes très importants de données et peuvent donc rapprocher certaines analyses d'une approche exhaustive. Cependant, un grand nombre de données ne garantit pas que toute la population soit représentée ni que les données soient exemptes de biais.

6. Quels sont les enjeux autour du choix d'un estimateur ?

Le choix d'un estimateur détermine en partie la qualité de l'estimation. Un bon estimateur doit notamment limiter les biais, être suffisamment précis et produire des résultats relativement stables d'un échantillon à l'autre. Son choix dépend du paramètre recherché, de la taille de l'échantillon et de la distribution des données.

7. Quelles sont les méthodes d'estimation d'un paramètre ? Comment en sélectionner une ?

On distingue principalement l'estimation ponctuelle et l'estimation par intervalle. L'estimation ponctuelle fournit une valeur unique pour approcher un paramètre, tandis que l'estimation par intervalle fournit une plage de valeurs possibles, comme un intervalle de confiance. Le choix dépend de la nature des données, du paramètre recherché, de la taille de l'échantillon et du niveau de précision souhaité.

8. Quels sont les tests statistiques existants ? À quoi servent-ils ? Comment créer un test ?

Il existe différents tests statistiques selon la nature des données et la question étudiée. Par exemple, le test de Shapiro-Wilk permet de tester la normalité d'une distribution, le χ^2 permet notamment de tester l'indépendance entre des variables qualitatives, et Spearman ou Kendall permettent d'étudier des relations entre des rangs.

Un test statistique commence par la formulation d'une hypothèse nulle H_0 et d'une hypothèse alternative H_1 . On choisit ensuite un seuil de risque, souvent fixé à 5 %, puis on calcule une statistique de test et une p-value. Si la p-value est inférieure au seuil choisi, on rejette généralement H_0 . Si elle est supérieure, on ne dispose pas de suffisamment d'éléments pour rejeter H_0 .

9. Que pensez-vous des critiques de la statistique inférentielle ?

La statistique inférentielle permet de tirer des conclusions sur une population à partir d'un échantillon, mais ses résultats comportent toujours une part d'incertitude. Ils dépendent de la qualité de l'échantillon, des hypothèses retenues et de la méthode statistique choisie. Une différence statistiquement significative n'est pas nécessairement importante dans la réalité et une p-value ne constitue pas une preuve absolue. Les résultats doivent donc toujours être interprétés en tenant compte des données, de la méthode utilisée et du contexte de l'étude.