

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 5. La statistique d'ordre des variables qualitatives

Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

20 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler des fonctions locales et comprendre la nécessité de factoriser son code en une liste de fonctions ou de procédures exécutant une tâche unique
- Créer des fonctions locales spécifiques au traitement d'un problème
- Comprendre l'analyse de variables qualitatives ordinales

2 Manipulations

1. Dans le dossier `src`, introduire le dossier `data` le fichier `classement-restaurants-paris-2023-par-enseignes.csv` disponible dans la `Seance-05` du `GitHub`
2. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
3. Isoler la colonne `Nombre d'établissement`.

4. Ordonner la liste obtenue avec la fonction locale `ordreDecroissant()` proposée. Elle prend en paramètre une liste.
5. Visualiser la loi rang-taille en créant une image de sortie.
6. L'image obtenue est illisible. Il vous faut convertir les axes en logarithme. Pour ce, utiliser la fonction locale `conversionLog()` proposée. Elle prend en paramètre une liste.
7. Est-il possible de faire un test sur les rangs ? (mettre votre réponse sous la forme d'un commentaire dans le fichier)
8. Dans le dossier `src`, introduire le dossier `data` le fichier `Le-Monde-HS-Etats-du-monde-2007-2026.csv` disponible dans la Seance-05 du GitHub
9. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
10. Isoler les colonnes « État », « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 »
11. En utilisant la fonction locale `ordrePopulation()`, ordonner de manière décroissante les listes « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 ». Elle prend en paramètres la liste à ordonner et la liste des États.
12. En utilisant la fonction locale `classementPays()`, préparer la comparaison des listes sur la population et la densité. Elle prend en paramètres les deux classements (pour le nombre d'habitants et pour la densité) obtenus avec `ordrePopulation()`. En classant le résultat avec la méthode `sort()`, vous obtenez une liste avec deux colonnes ordonnées par rapport au classement de 2007.
13. Isoler les deux colonnes sous la forme de liste différentes en utilisant une boucle
14. Dans la bibliothèque `scipy.stat`, utiliser les méthodes `spearmanr()` et `kendalltau()` pour calculer le coefficient de corrélation des rangs et la concordance des rangs. Les deux méthodes prennent en paramètres les deux classements que vous avez respectivement calculés pour le nombre d'habitants et pour la densité. Vous commenterez ce résultat dans votre rapport d'activité.

2.1 Bonus

Afin de vous faciliter la vie, car les codes n'étaient pas simples à trouver, vous avez utiliser des fonctions que j'ai créées. C'est l'un des bonus qui peut vous rapporter le plus de points. Vous devrez créer des fonctions locales permettant de calculer rapidement une analyse de rangs.

Pour les restaurants, vous avez à votre disposition une extraction des données du fichier `restaurants-paris-2017`. Les enseignes n'étant pas présentes, elles ont été reconstituées en comparant les adresses postales entre la liste des restaurants en 2017 et la liste des restaurants en 2023. Le résultat est le fichier

`classement-restaurants-paris-2017-par-enseignes.csv`. Vous devez proposer un algorithme et un code pour comparer le classement obtenu en 2017 et en 2023 en utilisant le coefficient de corrélation et la concordance des rangs.

Pour la population mondiale, 1. factoriser le code d'analyse des classements sous la forme d'une fonction renvoyant les coefficients de corrélation des rangs et la concordance des rangs ; 2. faire un algorithme et un code permettant d'analyser la concordance des rangs de l'ensemble des classements annuels de 2007 à 2026.