

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 6. Régression et corrélation statistique de
deux variables
Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à gérer les données censurées
- Manipulation les outils de la régression et de la corrélation simple

2 Manipulations

Existe-t-il un lien entre le produit intérieur brut (P.I.B.) et la consommation énergétique ?
Le fichier de données que vous allez analyser est issu des données de la Banque mondiale (<https://donnees.banquemondiale.org/>). Il regroupe deux jeux de données :

- le P.I.B. de chaque territoire (étatique ou non) de 1962 à 2024 en dollars courants (c'est-à-dire sans prendre en compte l'inflation) ;
- la consommation énergétique en kilogrammes équivalent pétrole de 1962 à 2024.

J'ai opéré les principales opérations de nettoyage, et fais en sorte que vous ayez le moins de difficultés possibles à obtenir le résultat recherché.

1. Il existe un décalage entre les données du P.I.B. et de la consommation énergétique. Il faut de fait sélectionner en utilisant `Pandas` les colonnes `PIB_2022` et `Utilisation_d_energie_2022` dans le fichier `pib-vs-energie.csv`.
2. Malheureusement, plusieurs données sont censurées. Il vous faut créer un algorithme qui ne sélectionnera que les couples complets, c'est-à-dire ayant une valeur pour le P.I.B. et la consommation énergétique. Dit autrement, vous devez exclure les données manquantes (aucune valeur pour l'un et l'autre), et les données partielles (une donnée chez l'une, mais pas l'autre).
3. On considère que la variable explicative est la consommation énergétique et la variable à expliquer est le P.I.B. Calculer une régression linéaire simple entre les deux colonnes avec la méthode `scipy.stats.linregress(x, y)` prenant en arguments `x`, la variable à expliquer, et `y`, la variable explicative.
4. Calculer la corrélation simple entre les deux colonnes. Vous pouvez utiliser indifféremment les bibliothèques `Pandas` ou `Scipy`.
5. Faire un graphique de synthèse permettant de visualiser la droite de régression obtenue.
6. Dans votre rapport, vous commenterez votre résultat sous la forme d'un ou deux paragraphes.

3 Bonus

Vous avez écrit un algorithme permettant de traiter deux colonnes se rapportant à la même année. Écrivez un algorithme permettant de généraliser votre résultat à toutes les années de 1962 à 2022. N'oubliez pas d'organiser correctement vos fichiers de sortie.