

Séance 6 Régression et corrélation statistique de deux variables

1. Quel est l'intérêt de passer des statistiques univariées aux statistiques bivariées ?

Les statistiques univariées étudient une seule variable, par exemple sa moyenne, sa médiane ou sa dispersion. Les statistiques bivariées étudient deux variables simultanément afin de déterminer s'il existe une relation entre elles. Elles permettent donc de dépasser la simple description pour analyser comment deux phénomènes peuvent varier ensemble.

2. Quelles différences opérez-vous entre corrélation et correspondances ? Qu'est-ce qu'un rapport de corrélation ?

La corrélation mesure l'intensité et le sens de la relation entre deux variables quantitatives. La correspondance concerne la relation entre des variables qualitatives, généralement étudiées à partir d'un tableau de contingence. Le rapport de corrélation permet de mesurer la liaison entre une variable quantitative et une variable qualitative.

3. Quelles différences faites-vous entre les valeurs marginales et les valeurs conditionnelles ? Pourquoi distinguer les deux ?

Les valeurs marginales correspondent aux distributions d'une variable considérée indépendamment de l'autre. Les valeurs conditionnelles décrivent au contraire la distribution d'une variable en fonction d'une catégorie ou d'une valeur de l'autre variable. Les distinguer permet de déterminer si la distribution d'une variable change lorsque l'on tient compte de l'autre.

4. Quelles différences faites-vous entre variance et covariance ?

La variance mesure la dispersion d'une variable autour de sa moyenne. La covariance étudie la manière dont deux variables varient ensemble. Une covariance positive signifie qu'elles ont tendance à évoluer dans le même sens, tandis qu'une covariance négative indique qu'elles ont tendance à évoluer en sens inverse.

5. Pourquoi mesurer la corrélation ou l'indépendance ?

Mesurer la corrélation permet de déterminer si deux variables évoluent ensemble et d'évaluer l'intensité et le sens de cette relation. Tester l'indépendance permet de déterminer si deux variables sont liées ou si leurs variations peuvent être considérées comme indépendantes. Cela permet d'identifier des relations statistiques entre différents phénomènes.

6. Quel est le principe de la méthode des moindres carrés ? À quoi sert-elle ?

La méthode des moindres carrés consiste à rechercher la droite qui représente au mieux la relation entre deux variables. Elle minimise la somme des carrés des écarts entre les valeurs réellement observées et les valeurs estimées par la droite. Elle est notamment utilisée pour calculer une droite de régression linéaire.

7. Expliquez en un court paragraphe ce qu'est la théorie de la corrélation simple.

La corrélation simple étudie la relation entre deux variables quantitatives. Elle permet de déterminer si elles évoluent dans le même sens, en sens inverse ou sans relation linéaire apparente. Le coefficient de corrélation varie entre -1 et +1 : une valeur proche de +1 indique une forte corrélation positive, une valeur proche de -1 une forte corrélation négative et une valeur proche de 0 une faible relation linéaire.

8. En quoi consiste le piège de l'autocorrélation ?

L'autocorrélation apparaît lorsque les observations d'une même variable ne sont pas indépendantes les unes des autres. En géographie, ce problème est particulièrement important car des espaces proches peuvent présenter des caractéristiques similaires simplement en raison de leur proximité spatiale. On risque alors d'interpréter comme une relation statistique ce qui provient en réalité de la structure spatiale des données.

9. Expliquez en un court paragraphe ce qu'est une régression linéaire.

La régression linéaire cherche à expliquer une variable à partir d'une autre en modélisant leur relation par une droite. On distingue une variable explicative et une variable à expliquer. La droite de régression permet de représenter la tendance générale de la relation et d'estimer la valeur de la variable à expliquer à partir de la variable explicative.

10. Quelle est la différence entre coefficient de corrélation et coefficient de détermination ?

Le coefficient de corrélation mesure l'intensité et le sens de la relation linéaire entre deux variables. Il varie entre -1 et +1. Le coefficient de détermination, noté R^2 , mesure la part de la variation de la variable à expliquer qui est expliquée par le modèle de régression. Il varie généralement entre 0 et 1 : plus il est proche de 1, plus le modèle explique une part importante de la variation observée.

11. Pourquoi faut-il tester les deux droites de régression ?

Les deux droites de régression ne répondent pas exactement à la même question. Une première peut permettre d'expliquer Y à partir de X, tandis que l'autre permet d'expliquer X à partir de Y. La régression n'est donc pas symétrique : inverser la variable explicative et la variable à expliquer modifie le modèle obtenu. Tester les deux permet de comprendre le sens de la relation et de choisir le modèle adapté à la question étudiée.