

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 6. Régression et corrélation statistique de deux variables

Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

22 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à gérer les données censurées
- Manipulation des outils de la régression et de la corrélation simple

2 Manipulations

Existe-il un lien entre le revenu brut disponible¹ et le pouvoir d'achat² par unité de consommation³ (U.C.) ? L'évolution du pouvoir d'achat est déflatée à l'aide de l'indice du prix de la dépense de consommation finale des ménages. Les données expriment l'évolution des deux indicateurs en pourcentage par rapport à l'année précédente. Cela se lit, pour 2025,

1. revenus dont disposent les ménages pour consommer ou pour investir après les opérations de redistribution

2. volume de biens et de services qu'un revenu permet d'acheter

3. 1 UC équivaut au premier adulte du ménage, $\frac{1}{2}$ UC équivaut aux personnes ayant un âge supérieur ou égal à 14 ans, et $\frac{1}{3}$ UC équivaut à une personne ayant un âge strictement inférieur à 14 ans

« En 2025, le pouvoir d'achat du revenu disponible brut diminue de 0,4 % par rapport à 2024. Ramené à une unité de consommation, il diminue de 0,7 %. ».

Le fichier `Revenu-vs-pouvoir.csv` est extrait de l'Institut national de la statistique et des études économiques (I.N.S.E.E.) ayant pour référence les comptes annuels selon la base de 2020.

— <https://www.insee.fr/fr/statistiques/2830244>

1. Sélectionner en utilisant `Pandas` les colonnes `Pouvoir_d_achat_par_unite_de_consommation` et `Pouvoir_d_achat_du_revenu_disponible_brut` dans le fichier `Revenu-vs-pouvoir.csv`.
2. On considère que la variable explicative est le revenu brut disponible et la variable à expliquer est l'unité de consommation. Calculer une régression linéaire simple entre les deux colonnes avec la méthode `scipy.stats.linregress(x, y)` prenant en arguments `x`, la variable à expliquer, et `y`, la variable explicative. Faire la même opération en inversant les deux variables.
3. Calculer la corrélation simple entre les deux colonnes de chaque régression obtenue. Vous pouvez utiliser indifféremment les bibliothèques `Pandas` ou `Scipy`.
4. Faire deux graphiques de synthèse permettant de visualiser chaque droite de régression obtenue et les enregistrer dans un dossier `img`.
5. Dans votre rapport, vous commenterez votre résultat sous la forme d'un ou deux paragraphes.

3 Bonus

À partir du fichier `Bonus-Revenu.csv`, essayez d'établir les régressions existantes entre les différentes lignes. L'unité est l'évolution par rapport à l'année précédente en pourcentage.